

RIVER_GRAPH

面向稀疏观测的河流溶解性有机碳（DOC）重建 ——基于河网拓扑与生态属性的图神经网络

密西西比河流域 · 571 个监测站点 · 1972–2026 逐月 DOC

Topology-aware graph neural networks for reconstructing sparse DOC observations in the Mississippi River Basin

1. 科学问题（一句话）

河流碳监测在空间和时间上都高度稀疏。能否利用河网本身的拓扑结构（连通性、流向、输移物理过程）和流域生态属性（土壤、地形、水文、气候），恢复从未被观测的 DOC 状态，从而降低流域碳通量估计的不确定性？

这个问题的现实背景，是监测数据本身的极度稀疏：

11,948

密西西比河流域内至少有一次
DOC 记录的 USGS 站点

约 570

其中有可用记录、进入图建模的
站点

8.9%

（站点 × 月）网格中真正被观测
的比例

换句话说，现有碳通量估计所依赖的观测底账里，超过九成的“站点-月份”格子是空的。传统的填补方式是把河流当作普通的空间点集（欧氏距离克里金、随机森林按特征外推），但河流不是普通空间——它是有方向的输移系统，上游站点对下游是因果输入，下游观测对上游是反向约束，而且每条河段的输移强度由河长、汇水面积、坡度、河级等物理属性决定。本项目的工作假设是：这些结构与生态信息，本身就携带了恢复缺失观测所需的信号。




图 1 密西西比河流域 571 个 DOC 监测站点示意（按图连通分量着色）。示意性渲染图，基于真实图统计（571 节点 / 562 条有向边）；管线等价图由 build_graph.py 生成。

2. 核心思想

把“稀疏站点上的零散观测”放进河网结构与流域生态背景中传播，是整条方法链的核心：



三个输入各自回答一个“普通空间方法回答不了”的问题：

- 稀疏观测——每个月只有少数站点有实测值，模型输入包含“已观测 DOC 通道 + 掩码”，让已有观测沿图传播到同月的空白站点；
- 河网图——通过 NLDI / NHDPlus 构建的有向图（上游 → 下游），每条边携带跳数距离、河长、汇水面积、坡度、河级等输移属性；
- 生态背景——每个站点所在集水区的土地利用、气候多年平均、土壤有机质、高程、基流指数（EPA StreamCat），刻画“这个站点为什么是这个碳性格”。

预测的单元是一个（站点，月）格子；DOC 在对数空间建模，指标换回 mg/L 报告。基准实验覆盖三种外推情形：E1 随机掩码（20/40/60%）、E2a 严格未来预测（2021 年后无任何观测）、E2b 监测网持续运行下的未来重建（2021 年后保留 20% 站点作为上下文，最接近真实业务场景）、E3 空间外推（整站留出 20%，检验“信息能否沿河网传到从未监测的站点”）。

3. 模型演化：每一步解决一个具体的生态/物理问题

模型不是一步到位堆出来的，而是在同一套冻结基准上逐级消融演化。每一级只改一件事，因此每一级的增益都能归因到具体的机制假设：

G0	普通 GCN	检验：河流是不是普通空间？把河网当无向图做邻居平均。结论：真实河网 > 随机图 > 无图（E1），且只有真实河网能在 E3 空间外推中迁移——拓扑本身是有效信息。
H1	有向关系 GCN	补上：上下游方向。上游、下游两个方向使用独立的权重通道（上游是因果输入，下游是反向约束）。是第一个在 E2 时间外推上击败随机森林的模型。
H2	输移门控 GCN	补上：输移强度的差异。边不再是等权重的——由跳数距离、河长、汇水面积、坡度、河级经 MLP 生成逐边门控权重，“河段输移”代替“均匀平均”。E2a/E2b 最优，E1 追平随机森林。
H2E+	生态背景	补上：生态异质性。把 StreamCat 集水区属性（土地利用、气候、土壤有机质、高程、基流）作为节点特征。修复了此前最差的空间迁移：E3 R^2 从 0.23 $\rightarrow$ 0.32。
	生态编码器	把生态背景从“原始特征”升级为“学习到的嵌入”（MLP 编码生态属性块，再与图表示融合）。当前最优模型：E2b MAE 0.96 / R^2 0.47；E3 最优种子 R^2 0.53。

注：演化阶梯中每一级都在同一组掩码、同一泄漏控制规则、同一早停协议下重跑，消融结论可复现（掩码与冻结结果存于 experiments/masks 与 experiments/frozen_results）。

4. 当前结果（关键数字）

4.1 主结果：三类外推场景（MAE mg/L，越低越好）

表 1 关键模型在三类基准上的表现（E1 为三种子均值 ± 标准差；E3 为三种子均值 ± 标准差；数据来自 experiments/results/summary.md）

模型	E1 随机掩码 r20	E2a 严格未来 预测	E2b 未来重建 (监测网运行中)	E3 空间外推 (整站留出)
站点均值	1.46	1.14	1.12	2.59 ± 0.45
克里金（欧氏空间）	2.15	—	1.51	2.05 ± 0.29
随机森林	1.42	1.11	1.11	2.07 ± 0.20
G0 普通 GCN（河网图）	1.74	1.45	1.38	1.97 ± 0.31
H1 有向河网	1.50	1.09	1.07	2.03 ± 0.23
H2 输移门控	1.41	1.10	1.05	2.01 ± 0.26
H2E + 生态背景	1.41	1.18	1.13	1.81 ± 0.21
H2X + 生态编码器（当前最优）	1.40	—	0.96	1.79 ± 0.28

E2a 上克里金无定义（测试月没有任何同期观测可插值）；H2X 的 E1 r40/r60 与 E2a 冻结批次仍在补跑，权威完整表见仓库 experiments/frozen_results/benchmark.csv。R² 口径：E2b 上 H2X 为 0.47（RF 为 0.18），E3 上最优种子达 0.53。

4.2 读法：三个场景分别说明什么

E2b（最贴近真实业务）：监测网持续运行、少数站点照常上报时，H2X 把 MAE 压到 0.96 mg/L，比随机森林（1.11）低约 14%，R² 从 0.18 提到 0.47——河网传播 + 生态编码带来的增益主要落在这里；

E3（空间外推）：所有方法都吃力（留出站的站点均值都到 2.59），但 GNN 家族整体优于空间插值与随机森林；生态背景把 R² 从 0.23 修复到 0.32，说明“这个站是什么生态性格”是空间迁移的关键缺失变量；

E1（随机掩码）：在轻掩码（20%）下 H2X 已略优于随机森林；60% 重掩码区间随机森林仍占优——图传播在观测极度稀薄时也会“断粮”。

5. 当前发现 与 待讨论的问题

5.1 两个值得讨论的发现

发现一：E3 的失败集中在源头小流域，而生态背景恰好能救回它们。

对 E3 误差的逐站归因显示，最大的失败来自密苏里河源头区的源头站点——这些站点与下游主干的“图距离”远、且水文气候背景与大河谷站点差异极大。加入 StreamCat 生态背景后，这些站点的 MAE 从 2.79 降到 2.21。这提示：空间迁移的瓶颈不是“图传得不够远”，而是模型不知道远端站点处于另一种生态状态。

发现二：极端 DOC 状态是系统性短板，而且它的成因“看不见”。

以 06438000 站为例的标签审计：该站 1978–1980 年出现一轮月均 DOC 高达 137.5 mg/L 的局部高值期（峰值 460，1980-07），1981 年后回落至个位数；同期流量与 DOC 的 Spearman 相关为 -0.00，上游站点全程干净——这是一段局部的、历史性的源区/土地利用或采样年代事件。在只有月均流量、没有事件与源区历史状态的条件，任何空间模型都没有依据外推出 460 这样的值。系统性低估极端值是可解释的科学局限，不是单纯的工程失败。

5.2 当前判断与下一步设想

当前结果显示，河网拓扑与生态属性能显著提升 DOC

重建的时间外推（E2b）与空间迁移（E3）能力，但在极端 DOC 状态下仍存在系统性不足。结合发现二，最可能的缺口是：模型没有时间状态——月均标签下的输移记忆、前期湿润/干旱过程、事件性冲刷都不可见。

下一步计划是在 H2X 基础上加入逐月时序建模（每个站点的图嵌入序列上接 GRU 类结构，暂名 HydroGRN-ST；设计文档中对应消融阶梯的 H3 级），并在 E2a/E2b 上检验时间记忆能否补上极端状态的缺口。

5.3 待讨论的三个问题

问题一（方向层面）：

加入时序建模（HydroGRN-ST）以恢复极端 DOC

状态，这个思路是否符合碳输移的生态过程认识？从生态学角度，月均分辨率下“前期过程记忆”对 DOC 的约束有多强？是否应优先做事件尺度而不是月尺度？

问题二（机制层面）：

发现一显示空间迁移瓶颈在“生态状态差异”而非“图距离”。除 StreamCat 现有的土壤/地形/气候/基流变量外，从河流碳循环角度，还应优先补充哪类集水区属性（如湿地比例、多年冻土、农业强度、植被生产力）？

问题三（数据层面）：

06438000 这类“历史局部高值期”标签，在建模上应作为真实但不可外推的状态保留（并在不确定度中体现），还是作为年代/方法效应的异常处理？这对碳通量总量估计的口径有影响，想进一步明确判断。

材料数据口径：全部指标取自仓库冻结结果（experiments/frozen_results/benchmark.csv 与 experiments/results/summary.md）；图结构为 571 站 / 562 条有向边（NLDI over NHDPlus，最大连通分量 407 节点）；标签为 USGS pcode 00681 月均 DOC，1972-04 至 2026-07 共 33,048 个已观测（站点，月）格子；复现管线与数据来源（USGS NWIS、WQP、NLDI/NHDPlus、EPA StreamCat）见仓库 README。